

---

# Lecture 5: Probabilities

---

PCL II, CL, UZH  
March 23, 2016



Universität  
Zürich<sup>UZH</sup>

# Contents

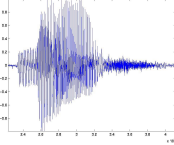
---

1. Probabilities: Language Model
2. Probability Theory Background
3. Conditional Probabilities and MLE
4. Chain Rule
5. Markov Model
6. Examples Language Modelling

# Probabilities

## Language Model

---

- Language Model is the distribution of sequence of words
- Applications
  - Handwriting recognition
  - Tagging  
 $p(\text{Adj Noun Verb Det Verb} \mid \text{"fruit flies like a banana"})$
  - speech recognition  
 $p(\text{"wreck a nice beach"} \mid \text{[audio waveform]})$ 
  - Machine Translation  
 $p(\text{"All your base are belong to us."} \mid \text{"君達の基地は、全てCATSがいただいた。"})$
  - Language Identification
    - Based on “Character-N-Grams” [Dunning, 1994]

# Probabilities

# Language Model

---

How do we get the probabilities?

# Contents

---

1. Probabilities: Language Model
2. Probability Theory Background
3. Conditional Probabilities and MLE
4. Chain Rule
5. Markov Model
6. Examples Language Modelling

# Probability Theory Background

---



Universität  
Zürich<sup>UZH</sup>

- Probability theory to predict how likely is that something will happen
- Experiment (or trial) observations are made  
*e.g.* Tossing a coin
- An experiment is a collection of basic outcomes
- Sample space  $\Omega$  all possible outcomes
  - Discrete: countable number of basic outcomes
  - Continuous: uncountable number of basic outcomes
- Event  $A$  a subset of  $\Omega$

# Probability Theory Background

---



Universität  
Zürich<sup>UZH</sup>

Probability distribution: probability 1 is distributed throughout the sample space  $\Omega$

- Each basic outcome has a probability  
*e.g.*  $P(\text{heads}) = 0.5$ ;  $P(\text{tails}) = 0.5$ ;
- Restrictions:
  - all  $p$ 's have to be between 0 and 1
  - the sum of all  $p$ 's over all possible outcomes of the same event has to be 1



# Probability Theory Background

---

- Uniform distribution: all parameters equal  $1/N$



- Skewed distribution and others





# Probability Theory Background

---



Universität  
Zürich<sup>UZH</sup>

- is 0.003 "probable"?

# Probability Theory Background

---

- is 0.003 "probable"?
  - for 3 possible outcomes?
  - for 1000 possible outcomes
    - where all other probabilities are 0.000997?
    - where another outcome has a probability of 0.1?

# Probability Theory Background

## Example



Universität  
Zürich<sup>UZH</sup>

A fair coin is tossed *3 times*.

What is the chance of *2 heads*?

Experiment = ?


$\Omega = ?$

a basic outcome = ?

Probability distribution = ?

$A = ?$

$P(A) = ?$



# Probability Theory Background

## (In)dependent Events

---



- Two events  $A, B$  are independent if
  - $P(A \cap B) = P(A)P(B)$  or
  - $P(A) = P(A|B)$  when  $P(B) > 0$

*e.g.* landing on heads after tossing a coin
- Otherwise  $A, B$  are dependent
  - $P(A|B) = P(A \cap B) / P(B)$  when  $P(B) > 0$

The multiplication rule:

  - $P(A \cap B) = P(B)P(A|B) = P(A)P(B|A)$  also when  $P(B) = 0$
- Words in a sentence, text, ... are dependent.

# Contents

---

1. Probabilities: Language Model
2. Probability Theory Background
3. **Conditional Probabilities and MLE**
4. Chain Rule
5. Markov Model
6. Examples Language Modelling

# Conditional Probabilities

## Maximum Likelihood Estimate (MLE)

---

der Wagen	10
der schnelle	2
der Mensch	3
schnelle Wagen	5

Q: What is the probability that *Wagen* follows *der*?  
 $p(\text{Wagen}|\text{der}) = ?$

# Conditional Probabilities

## Maximum Likelihood Estimate (MLE)

---

- What probability estimates should we use for estimating the next word?
  - Absolute frequency:  $f(x)$
  - Relative frequency:  $f(x)/N$

# Conditional Probabilities

## Maximum Likelihood Estimate (MLE)

---

- What probability estimates should we use for estimating the next word?
  - Absolute frequency:  $f(x)$
  - **Relative frequency:  $f(x)/N$**
- Maximum Likelihood Estimate (MLE)

$$P_{\text{MLE}}(w_1 \dots w_n) = C(w_1 \dots w_n)/N$$

$$P_{\text{MLE}}(w_n | w_1 \dots w_{n-1}) = C(w_1 \dots w_n) / C(w_1 \dots w_{n-1})$$



# Conditional Probabilities

## Maximum Likelihood Estimate (MLE)

---

der Wagen	10
der schnelle	2
der Mensch	3
schnelle Wagen	5

Q: What is the probability that *Wagen* follows *der*?

$$p(\text{Wagen}|\text{der}) = ?$$

$$P(\text{Wagen}|\text{der}) = f(\text{der}, \text{Wagen})/f(\text{der}) = 10/15$$

# Conditional Probabilities

## Maximum Likelihood Estimate (MLE)

---

Conditional Probabilities in Python:  
Nested dictionaries

```
f = {"der": {"Wagen": 10, "schnelle": 2, "Mensch": 3},  
     "schnelle": {"Wagen": 5, "Mensch": 2}}
```

```
total = sum(f["der"].values())  
f["der"]["Wagen"]/float(total)
```

# Conditional Probabilities

## Maximum Likelihood Estimate (MLE)

---

Conditional Probabilities in Python:

`nltk.ConditionalFreqDist`

```
import nltk
```

```
b_a = [("der", "Wagen"), ("der", "Wagen"), ("der", "Wagen"),  
       ("der", "Wagen"), ("der", "Wagen"), ("der", "Wagen"),  
       ("der", "Wagen"), ("der", "Wagen"), ("der", "Wagen"),  
       ("der", "Wagen"), ("der", "schnelle"), ("der", "schnelle"),  
       ("der", "Mensch"), ("der", "Mensch"), ("der", "Mensch"),  
       ("schnelle", "Wagen"), ("schnelle", "Wagen"), ("schnelle", "Wagen"),  
       ("schnelle", "Wagen"), ("schnelle", "Wagen"), ("schnelle", "Mensch"),  
       ("schnelle", "Mensch")]
```

```
cfd = nltk.ConditionalFreqDist(b_a)
```

# Conditional Probabilities

## Maximum Likelihood Estimate (MLE)

---

Conditional Probabilities in Python:

`nltk.ConditionalFreqDist`

```
print cfd["der"]
print cfd["schnelle"]
print cfd["der"]["Wagen"]
print sum(cfd["der"].values())
print cfd["der"]["Wagen"]/float(sum(cfd["der"].values()))

cfd.tabulate()
cfd.plot()
```

# Conditional Probabilities

---

Probability of a text?

How can we generalize it to several events?

# Contents

---

1. Probabilities: Language Model
2. Probability Theory Background
3. Conditional Probabilities and MLE
- 4. Chain Rule**
5. Markov Model
6. Examples Language Modelling

# Chain Rule

---

- Conditional Probability

$$P(A|B) = P(A \cap B) / P(B) \quad \text{when } P(B) > 0$$

- The multiplication rule:

$$P(A \cap B) = P(B)P(A|B) = P(A)P(B|A) \text{ also when } P(B) = 0$$

# Chain Rule

---

- Conditional Probability

$$P(A|B) = P(A \cap B) / P(B) \quad \text{when } P(B) > 0$$

- The multiplication rule:

$$P(A \cap B) = P(B)P(A|B) = P(A)P(B|A) \text{ also when } P(B) = 0$$

Chain Rule generalization of multiplication rule:

$$P(A_1 \cap \dots \cap A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 \cap A_2) \dots P(A_n|A_1 \cap \dots \cap A_{n-1})$$



# Chain Rule

---

Chain rule for Texts:

$$P(w_1, \dots, w_l) = \prod_{n=1}^l P(w_n | w_1, \dots, w_{n-1})$$

# Chain Rule

---

Chain rule for Texts:

$$P(w_1, \dots, w_l) = \prod_{n=1}^l P(w_n | w_1, \dots, w_{n-1})$$

Problem: Data sparseness  $\longrightarrow$  Zero probabilities

Solution: only N-Grams - Markov assumption

# Contents

---

1. Probabilities: Language Model
2. Probability Theory Background
3. Conditional Probabilities and MLE
4. Chain Rule
- 5. Markov Model**
6. Examples Language Modelling

# Markov Model

---

## Markov Assumption

- A word  $w_n$  depends only on  $k$  previous words  $w_{n-k}, \dots, w_{n-1}$ , where  $0 \leq k < n$

# Markov Model

---

## Markov Assumption

- A word  $w_n$  depends only on  $k$  previous words  $w_{n-k}, \dots, w_{n-1}$ , where  $0 \leq k < n$

## Markov Models

Unigram ( $k = 0$ ) Normal word frequency

Bigram ( $k = 1$ )  $w_n$  depends on  $w_{n-1}$

Trigram ( $k = 2$ )  $w_n$  depends on  $w_{n-2}, w_{n-1}$

# Markov Model

## Example: Unigram

---



Universität  
Zürich<sup>UZH</sup>

Was sich seit Monaten angedeutet hatte , was nach dem letzten , ernüchternden Vorbereitungstreffen der Unterhändler **in** Barcelona keine Überraschung mehr ist , es reift nun zur sicheren Prognose : Das **in** diversen Konferenzen beschworene Ziel , **in** diesem Jahr noch den soliden Rahmen für ein globales Klimaschutz-Abkommen **in** der Nachfolge des Kyoto-Protokolls zu zimmern , ist illusorisch geworden . Daran ist nicht mehr zu zweifeln , wenn nicht einmal der dänische Ministerpräsident Lars Løkke Rasmussen als Repräsentant des traditionell optimistisch auftretenden Gastgebers noch an einen Erfolg glaubt . Kopenhagen wird eine Station von vielen werden auf dem schwierigen Weg der Staatengemeinschaft , die Treibhausgase **in** diesem Jahrhundert gerade noch auf ein halbwegs erträgliches Ausmaß zu begrenzen .

$$P(\text{in}) = ?$$

# Markov Model

## Example: Unigram

---



Was sich seit Monaten angedeutet hatte , was nach dem letzten , ernüchternden Vorbereitungstreffen der Unterhändler **in** Barcelona keine Überraschung mehr ist , es reift nun zur sicheren Prognose : Das **in** diversen Konferenzen beschworene Ziel , **in** diesem Jahr noch den soliden Rahmen für ein globales Klimaschutz-Abkommen **in** der Nachfolge des Kyoto-Protokolls zu zimmern , ist illusorisch geworden . Daran ist nicht mehr zu zweifeln , wenn nicht einmal der dänische Ministerpräsident Lars Løkke Rasmussen als Repräsentant des traditionell optimistisch auftretenden Gastgebers noch an einen Erfolg glaubt . Kopenhagen wird eine Station von vielen werden auf dem schwierigen Weg der Staatengemeinschaft , die Treibhausgase **in** diesem Jahrhundert gerade noch auf ein halbwegs erträgliches Ausmaß zu begrenzen .

$$P(\text{in}) = \text{count}(\text{in}) / \text{count}(\text{all words})$$

$$P(\text{in}) = 5 / 117 \approx 0.042$$

# Markov Model

## Example: Bigram

---



Universität  
Zürich<sup>UZH</sup>

Was sich seit Monaten angedeutet hatte , was nach dem letzten , ernüchternden Vorbereitungstreffen der Unterhändler in Barcelona keine Überraschung mehr ist , es reift nun zur sicheren Prognose : Das in diversen Konferenzen beschworene Ziel , **in diesem** Jahr noch den soliden Rahmen für ein globales Klimaschutz-Abkommen in der Nachfolge des Kyoto-Protokolls zu zimmern , ist illusorisch geworden . Daran ist nicht mehr zu zweifeln , wenn nicht einmal der dänische Ministerpräsident Lars Løkke Rasmussen als Repräsentant des traditionell optimistisch auftretenden Gastgebers noch an einen Erfolg glaubt . Kopenhagen wird eine Station von vielen werden auf dem schwierigen Weg der Staatengemeinschaft , die Treibhausgase **in diesem** Jahrhundert gerade noch auf ein halbwegs erträgliches Ausmaß zu begrenzen .

$$P(\text{diesem}|\text{in}) = ?$$



# Markov Model

## Example: Bigram

---



Universität  
Zürich<sup>UZH</sup>

Was sich seit Monaten angedeutet hatte , was nach dem letzten , ernüchternden Vorbereitungstreffen der Unterhändler in Barcelona keine Überraschung mehr ist , es reift nun zur sicheren Prognose : Das in diversen Konferenzen beschworene Ziel , **in diesem** Jahr noch den soliden Rahmen für ein globales Klimaschutz-Abkommen in der Nachfolge des Kyoto-Protokolls zu zimmern , ist illusorisch geworden . Daran ist nicht mehr zu zweifeln , wenn nicht einmal der dänische Ministerpräsident Lars Løkke Rasmussen als Repräsentant des traditionell optimistisch auftretenden Gastgebers noch an einen Erfolg glaubt . Kopenhagen wird eine Station von vielen werden auf dem schwierigen Weg der Staatengemeinschaft , die Treibhausgase **in diesem** Jahrhundert gerade noch auf ein halbwegs erträgliches Ausmaß zu begrenzen .

$$P(\text{diesem}|\text{in}) = P(\text{in}, \text{diesem})/P(\text{in})$$

# Markov Model

## Example: Bigram

---



$$P(\text{diesem}|\text{in}) = P(\text{in, diesem})/P(\text{in})$$

$$P(\text{in diesem}) = P(\text{in diesem}) / \# \text{bigrams}$$

$$P(\text{in diesem}) = 2/116$$

$$P(\text{diesem}|\text{in}) = \frac{\frac{2}{116}}{\frac{5}{117}} \approx 0.411$$

# Markov Model

## Example: Sentence probability

---



Sentence: This sentence has 5 tokens

→ Bigram model?

→  $P(\text{This sentence has 5 tokens})$

$$P(\text{This}|\text{..}) \times P(\text{sentence}|\text{this}) \times P(\text{has}|\text{sentence}) \times P(5|\text{has}) \times P(\text{tokens}|5)$$

# Markov Model

## Python - defaultdict

---



```
def count1(text):  
    absfreqs = {}  
    for word in text.split():  
        absfreqs[word] = absfreqs.setdefault(word, 0) + 1  
    return absfreqs
```

# Markov Model

## Python - defaultdict

---



```
def count1(text):  
    absfreqs = {}  
    for word in text.split():  
        absfreqs[word] = absfreqs.setdefault(word, 0) + 1  
    return absfreqs
```

or using defaultdict:

```
from collections import defaultdict  
  
def count2(text):  
    freqs = defaultdict(int)  
    for word in text.split():  
        freqs[word] += 1  
    return freqs
```

# Markov Model

## Python - defaultdict

---



*This is a sentence . Each sentence has a number of words.  
The number of sentences is 3.*

Using nested dictionaries (Slide 19)

```
{ 'a': { 'sample': 1, 'number': 1 }, 'sentence': { 'has': 1, ' ': 1 },  
None: { 'This': 1, 'of': { 'words': 1, 'sentences': 1 },  
'is': { 'a': 1, '3': 1 }, 'sentences': { 'is': 1 }, 'number': { 'of': 2 },  
' ': { 'The': 1, 'Each': 1 }, 'sample': { 'sentence': 1 },  
'This': { 'is': 1 }, '3': { ' ': 1 }, 'words': { ' ': 1 },  
'Each': { 'sentence': 1 }, 'The': { 'number': 1 }, 'has': { 'a': 1 }}
```

# Markov Model

## Python - defaultdict

---

Using defaultdict:

```
def count_bigrams(text):  
    f = defaultdict(lambda: defaultdict(int))  
    hist = None  
    for word in text:  
        f[hist][word] += 1  
        hist = word  
    return f
```

# Contents

---

1. Probabilities: Language Model
2. Probability Theory Background
3. Conditional Probabilities and MLE
4. Chain Rule
5. Markov Model
6. Examples Language Modelling



# Examples Language Modelling

## Statistical Machine Translation (SMT)

---

- Essential component of any SMT system
- LM ensures fluent sentences on the target side
  - It helps to decide about word order:  
$$p_{\text{LM}}(\text{the house is small}) > p_{\text{LM}}(\text{small the is house})$$
  - and word translation:  
*Haus* has multiple translations (*house, home, ...*)  
$$p_{\text{LM}}(\text{I am going } \textit{home}) > p_{\text{LM}}(\text{I am going } \textit{house})$$

# Examples Language Modelling

## Optical Character Recognition (OCR)

---

- task: recognize the characters in a picture and generate the text, corresponding to them
- challenges:
  - formatting, location, picture-text mix
  - specific lexicon
  - font, italics/etc.
  - problems with old paper
  - sub-script/super-script
  - etc.

<http://kitt.cl.uzh.ch/kitt/kokos/>

---

# Lecture 5: Probabilities

---

PCL II, CL, UZH  
March 23, 2016



Universität  
Zürich<sup>UZH</sup>